IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

FIFA WORLD CUP 2026

Grupo 7

Realizado por:
André Agaci, Newton Rück, Davi Augustus

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

A COPA DA EXPANSÃO

O DESAFIO DE 2026

Com 48 seleções e sedes triplas (EUA, Canadá, México), a Copa de 2026 apresenta uma complexidade logística e competitiva sem precedentes.

O projeto tem como objetivo cruzar e modelar dados históricos para mitigar o fator de incerteza inerente ao futebol, permitindo estimar e prever a probabilidade de desempenho das seleções nacionais ao longo de todo o torneio.

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

PERGUNTAS ORIENTADORAS

TESTE DE HIPÓTESES

JOGAR EM ESTÁDIOS NÃO NEUTROS (MANDANTE) ALTERA SIGNIFICATIVAMENTE A MÉDIA DE GOLS MARCADOS?

REGRESSÃO LINEAR

O RANKING DA FIFA DE UMA SELEÇÃO ANTES DO TORNEIO CONSEGUE PREVER O NÚMERO DE GOLS MARCADOS POR ELA NA COPA?

APRENDIZADO DE MÁQUINA SUPERVISIONADO

COMO MODELOS DE CLASSIFICAÇÃO PODEM PREVER AS PROBABILIDADES DOS RESULTADOS DOS JOGOS PARA ALIMENTAR A SIMULAÇÃO DA COPA DO MUNDO DE 2026?

APRENDIZADO DE MÁQUINA NÃO SUPERVISIONADO

QUAIS OS PRINCIPAIS PADRÕES IDENTIFICADOS NAS SELEÇÕES QUE JOGARAM NA COPA DO MUNDO EM 2022?

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

TESTE DE HIPÓTESES

JOGAR EM ESTÁDIOS NÃO NEUTROS (MANDANTE) ALTERA SIGNIFICATIVAMENTE A MÉDIA DE GOLS MARCADOS?

Valor-p : 1.6186e-58

Média Gols (Casa) : 1.67

Média Gols (Fora) : 1.08

Análise Estatística

Por meio do Teste T de Welch (scipy.stats) Testamos a média de gols de seleções em campo neutro vs. campo próprio.

Resultado esperado:

Rejeição da hipótese nula com p-valor < 0.05, confirmando que o local influencia o desempenho ofensivo.

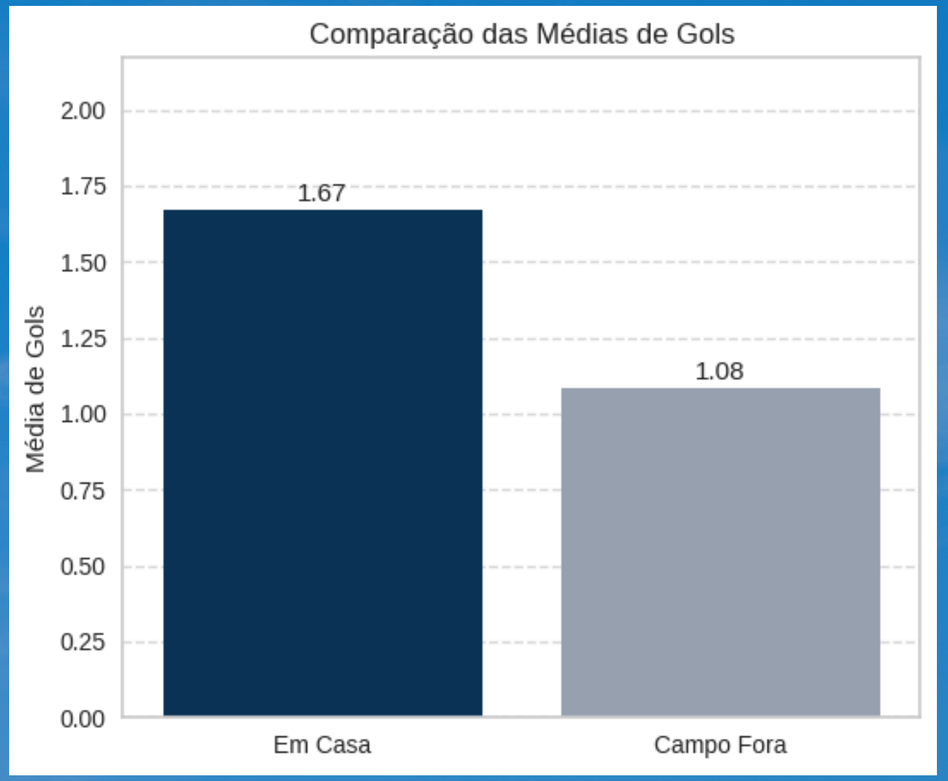

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

REGRESSÃO LINEAR

A VARIÁVEL TARGET (Y)

Escolhemos como variável alvo o **total de gols marcados** por cada seleção ao longo da Copa do Mundo. Essa variável foi obtida após somar os gols feitos em todos os jogos de cada equipe dentro da competição.

A VARIÁVEL FEATURE (X)

A variável explicativa utilizada foi o **ranking FIFA** médio de cada seleção. Como rankings menores representam equipas mais fortes, o eixo X foi invertido no gráfico para tornar a leitura mais intuitiva visualmente.

Após definir a variável explicativa X como o ranking médio da FIFA e a variável resposta Y como o total de gols marcados, a regressão linear foi aplicada para investigar a existência de uma relação entre essas duas medidas, com a análise buscando verificar se **seleções com melhor posicionamento no ranking tendem a apresentar maior eficiência ofensiva em Copas do Mundo.**

RESULTADOS OBTIDOS

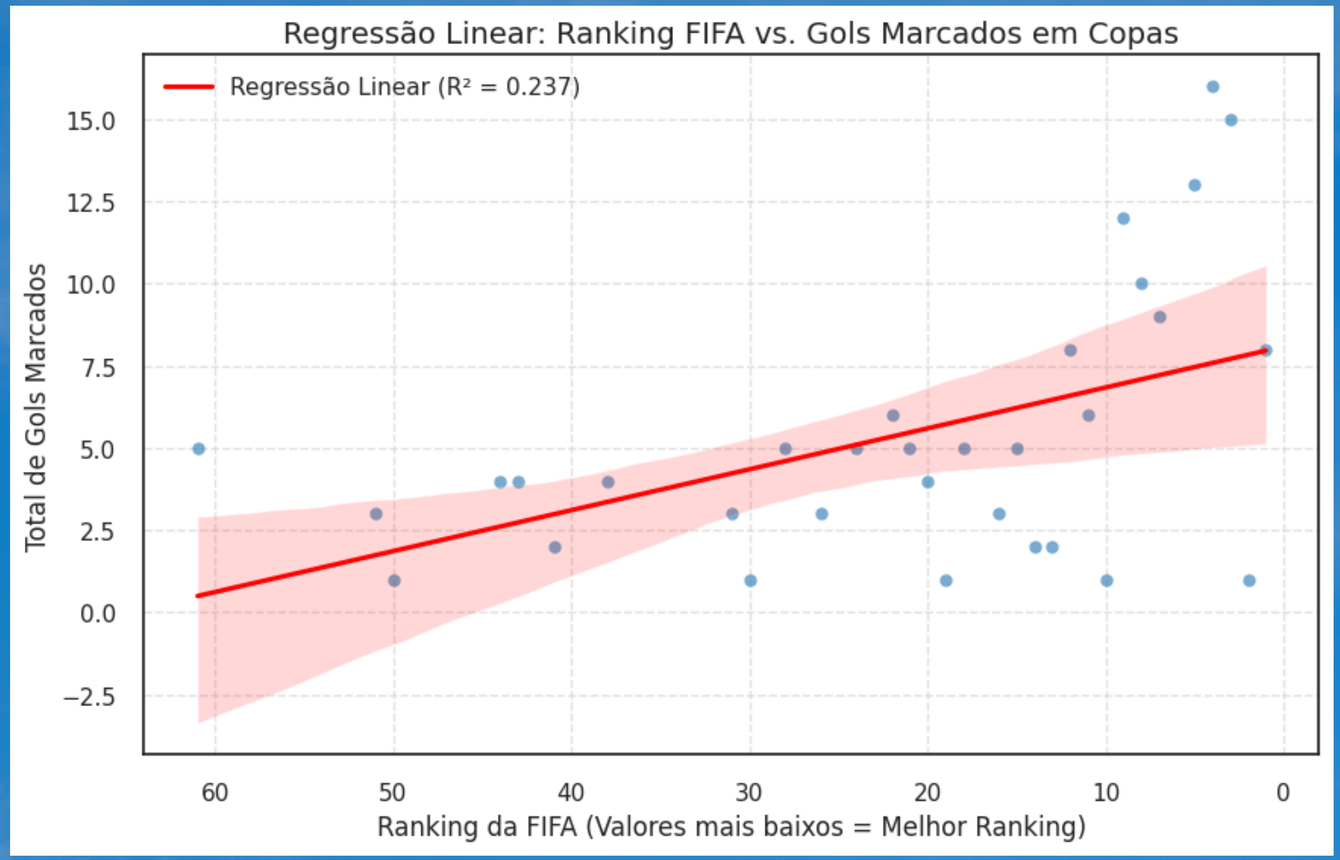

A regressão linear confirma que o Ranking da FIFA influencia a quantidade de gols na Copa. Seleções mais bem posicionadas tendem, de fato, a marcar mais (coeficiente de -0.124). Contudo, o R^2 de 0.237 revela que o ranking explica apenas 23,7% desse sucesso ofensivo. Além da existência de equipes com nível semelhante apresentando desempenhos ofensivos distintos. Isso prova analiticamente que, apesar da vantagem técnica inicial, o desempenho em um torneio curto é majoritariamente definido por variáveis externas.

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

APRENDIZADO DE MÁQUINA NÃO SUPERVISIONADO

QUAIS OS PRINCIPAIS PADRÕES IDENTIFICADOS NAS SELEÇÕES QUE JOGARAM NA COPA DO MUNDO EM 2022?

- Cluster 0
  - Desempenho próximo ao médio
  - Possível bom resultado em jogos anterirores
- Cluster 1
  - Desempenho ruim em relação ao desempenho médio
  - Possíveis resultados ruins em jogos passados e na Copa
- Cluster 2
  - Alto desempenho em relação à média
  - Bons resultados na Copa

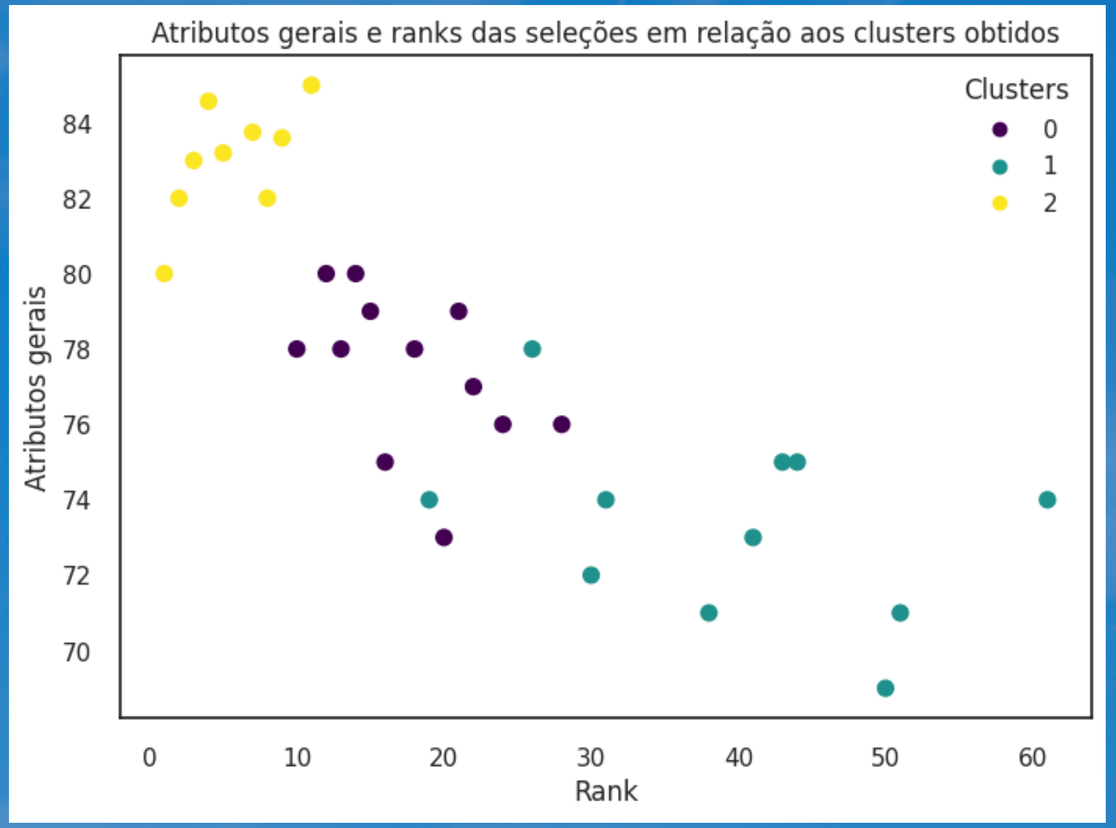

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

APRENDIZADO DE MÁQUINA SUPERVISIONADO

COMO MODELOS DE CLASSIFICAÇÃO PODEM PREVER AS PROBABILIDADES DOS RESULTADOS DOS JOGOS PARA ALIMENTAR UMA SIMULAÇÃO DA COPA DO MUNDO DE 2026?

A VARIÁVEL TARGET (Y)

Escolhemos como target a variável que indica se o Time A ganhou ou perdeu do Time B, sendo um problema de classificação binária, respectivamente 1, 0. Empates foram removidos do treino para forçar o modelo a aprender características de um vencedor definitivo.

AS VARIÁVEIS FEATURE (X)

O modelo tomou suas decisões baseadas em

- Força Historica
- Momento Atual
- Qualidade do Elenco
- Contexto do Jogo

MODELO ESCOLHIDO

Escolhemos o **Random Forest Classifier** porque ele combina a opinião de muitas árvores de decisão, como uma votação entre vários “especialistas”, tornando as previsões mais estáveis em um esporte imprevisível como o futebol. Em vez de depender de uma única árvore que poderia decorar os resultados históricos, usamos centenas de árvores rasas, o que reduz o overfitting e foca em padrões reais de vitória. Além disso, o modelo gera probabilidades para cada resultado, que servem de insumo direto para as simulações de Monte Carlo do torneio.

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

RESULTADOS OBTIDOS

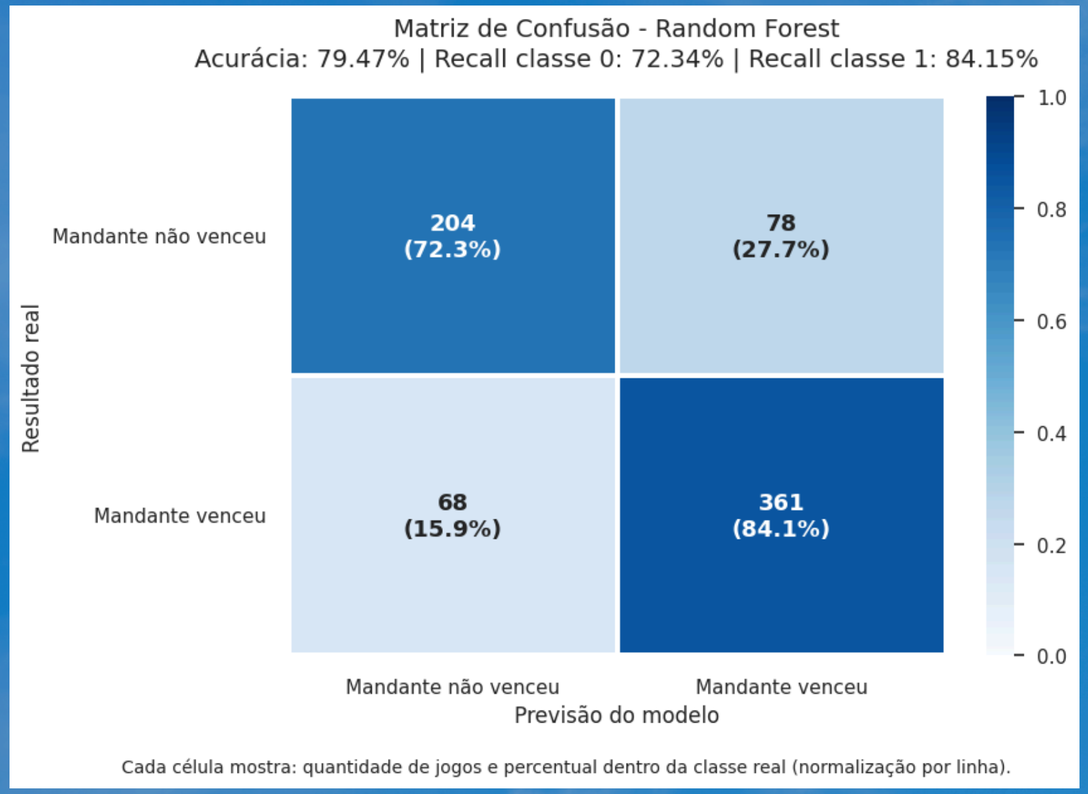

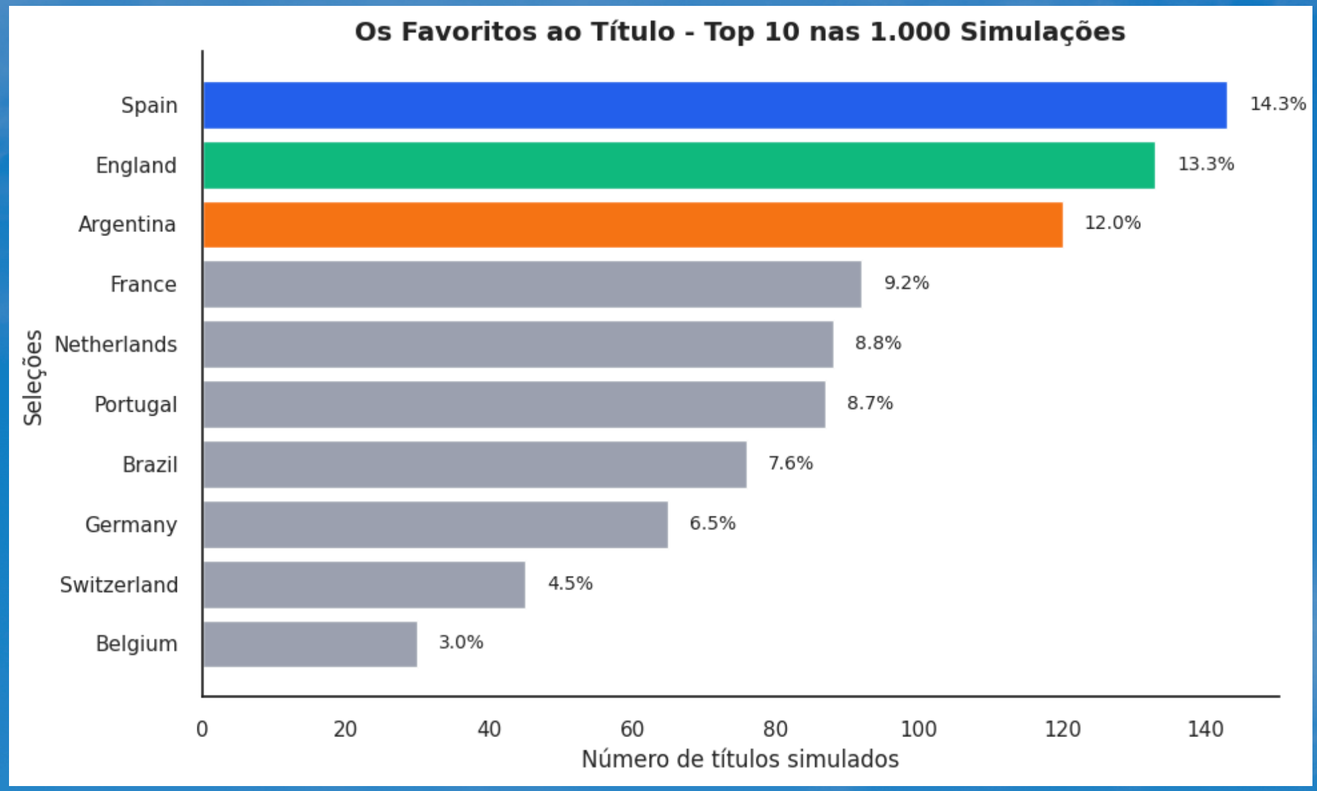

O modelo alcançou acurácia de 79,47%, mostrando boa capacidade de prever o resultado dos confrontos a partir das variáveis apresentadas; a matriz de confusão indica que ele é mais eficiente para identificar vitórias do mandante (recall de 84,15%) do que partidas em que o mandante não vence (recall de 72,34%), o que sugere que o modelo captura bem a vantagem de jogar em casa, embora ainda apresente certa tendência a superestimar vitórias do mandante.

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

CONCLUSÃO

O VEREDITO DO DATASET

Nosso projeto demonstra como um conjunto histórico de partidas da Copa do Mundo pode ser tratado, analisado e modelado para extrair insights sobre desempenho das seleções, testar estatisticamente o impacto de fatores como mando de campo e, a partir daí, treinar modelos de probabilidade de vitória capazes de alimentar simulações de torneios completos, oferecendo uma visão quantitativa dos possíveis cenários da Copa de 2026.

CAMPEÃO FIFA WORLD CUP 2026

ESPANHA

INGLATERRA

ARGENTINA

IMD1151 – CIÊNCIAS DADOS – T02 (2026.1)

OBRIGADO PELA ATENÇÃO

https://github.com/EnzoAlvesBarcelosGripp/wc26-match-predictor